

UNIVERSIDADE PRESBITERIANA MACKENZIE

Karla Maria Ramos da Silva (10730503)

Oscar Luz (10435099)

Rafael Hessel Sichetti (10375395)

Vitor Assunção Rocha (10440984)

**DESENVOLVIMENTO DE UM SISTEMA DE RECOMENDAÇÃO PARA
PRODUTOS FITNESS UTILIZANDO O DATASET DE AVALIAÇÕES DA
AMAZON**

SÃO PAULO

2026

SUMÁRIO

1. INTRODUÇÃO.....	3
1.1 Contexto do Trabalho	3
1.2 Motivação	4
1.3 Justificativa.....	5
1.4 Objetivo Geral e Objetivos Específicos	5
2. REFERENCIAL TEÓRICO.....	6
2.1 Sistemas de Recomendação no Comércio Eletrônico	6
2.2 Principais Técnicas de Recomendação.....	6
2.3 Métricas de Avaliação e Desempenho.....	7
2.4 Tendências Modernas: Deep Learning e Análise de Sentimentos	7
2.5 O Dataset de Avaliações da Amazon	7
3. METODOLOGIA.....	8
3.1 Descrição da Base de Dados.....	8
3.2 Pré-processamento e Limpeza dos Dados	10
3.3 Construção da Matriz Usuário-Produto.....	10
3.4 Similaridade do Cosseno e Geração de Recomendações	11
4. RESULTADOS	12
4.1 Análise Exploratória dos Dados	12
4.2 Desempenho do Modelo Baseline	12
4.3 Modelo Aprimorado — Filtragem Colaborativa Item-Item.....	13
5. APRESENTAÇÃO DA ETAPA 4 NA COMUNIDADE.....	14
6. CONCLUSÃO E TRABALHOS FUTUROS	18
6.1 Recapitulação do Trabalho	18
6.2 Conclusão	19
6.3 Melhorias no Projeto	19
6.4 Trabalhos Futuros.....	20
REFERÊNCIAS	21
APÊNDICES	22

1. INTRODUÇÃO

1.1 Contexto do Trabalho

O crescimento do comércio eletrônico tem transformado a forma como consumidores pesquisam, avaliam e adquirem produtos. Plataformas digitais reúnem milhares de itens disponíveis em diferentes categorias, o que torna o processo de escolha cada vez mais complexo para os usuários. Nesse contexto, os sistemas de recomendação têm se consolidado como ferramentas importantes para auxiliar consumidores na descoberta de produtos relevantes de acordo com seus interesses e comportamentos de compra. De acordo com Ricci, Rokach e Shapira (2011), os sistemas de recomendação utilizam dados históricos de interação entre usuários e itens para sugerir conteúdos personalizados, aumentando a eficiência das plataformas digitais e melhorando a experiência do consumidor.

Entre as empresas que utilizam amplamente esse tipo de tecnologia, destaca-se a Amazon, uma das maiores plataformas de comércio eletrônico do mundo. A empresa disponibiliza milhões de produtos em diversas categorias, incluindo itens relacionados à prática de atividades físicas e bem-estar. Nesse ambiente digital, os sistemas de recomendação desempenham um papel fundamental ao sugerir produtos semelhantes ou complementares aos interesses dos usuários, contribuindo para facilitar a tomada de decisão de compra e aumentar o engajamento na plataforma.

Dentro do conjunto de dados disponibilizado publicamente por pesquisadores da University of California San Diego, destacam-se os datasets de avaliações de produtos da Amazon, organizados e mantidos pelo pesquisador Julian McAuley. Esses dados contêm informações sobre interações entre usuários e produtos, incluindo avaliações, identificadores de itens e registros de consumo. Esse tipo de base de dados é amplamente utilizado em pesquisas de ciência de dados e aprendizado de máquina voltadas ao desenvolvimento e avaliação de sistemas de recomendação (MCAULEY et al., 2015).

Considerando o crescimento do mercado de produtos relacionados à saúde e ao condicionamento físico, a análise de dados desse segmento pode contribuir para o desenvolvimento de soluções tecnológicas capazes de auxiliar consumidores na escolha de equipamentos e acessórios fitness. Dessa forma, este projeto tem como foco a utilização do dataset de avaliações da Amazon para desenvolver um sistema de recomendação de produtos fitness, utilizando técnicas de ciência de dados para identificar padrões de consumo e sugerir itens relevantes para os usuários.

1.2 Motivação

A escolha do tema deste projeto está relacionada à experiência profissional do grupo na área de vendas, especialmente em ambientes de atacado e varejo. O trabalho nessas áreas permite observar, na prática, como o comportamento de compra dos consumidores influencia diretamente as estratégias de vendas, reposição de produtos e tomada de decisão nas empresas. No cotidiano do comércio, é comum lidar com grande variedade de produtos e diferentes perfis de clientes, o que torna importante compreender quais itens possuem maior probabilidade de interesse para determinados consumidores.

Nesse contexto, a utilização de sistemas de recomendação surge como uma alternativa tecnológica capaz de apoiar empresas na análise de dados de consumo e na sugestão de produtos relevantes para os clientes. Em plataformas de comércio eletrônico, como a Amazon, esses sistemas são amplamente utilizados para indicar produtos semelhantes ou complementares, auxiliando os consumidores durante o processo de compra e contribuindo para melhorar a experiência do usuário.

A escolha do tema também está relacionada ao interesse em aplicar conhecimentos de ciência de dados em problemas reais do setor comercial. Como profissionais que atuam em áreas ligadas a vendas e relacionamento com clientes, compreender como os dados podem ser utilizados para identificar padrões de consumo e gerar recomendações automáticas torna-se um diferencial importante para o desenvolvimento profissional.

Além disso, o uso do dataset público de avaliações de produtos da Amazon, disponibilizado pelo pesquisador Julian McAuley da University of California San Diego, permite trabalhar com uma base de dados real utilizada em pesquisas acadêmicas sobre sistemas de recomendação. Dessa forma, o projeto possibilita a aplicação prática de técnicas de análise de dados para desenvolver um modelo capaz de sugerir produtos fitness com base nas interações registradas no conjunto de dados.

1.3 Justificativa

A realização deste trabalho busca unir a experiência prática dos integrantes do grupo na área comercial com os conhecimentos adquiridos na área de ciência de dados, demonstrando como a análise de dados pode contribuir para melhorar estratégias de venda e recomendação de produtos no ambiente digital. O segmento de produtos fitness apresenta crescimento consistente no comércio eletrônico brasileiro, tornando relevante o desenvolvimento de ferramentas que melhorem a experiência de descoberta de produtos nesse nicho.

Do ponto de vista acadêmico, o projeto se justifica pela aplicação integrada de técnicas de pré-processamento de dados, análise exploratória, aprendizado de máquina e avaliação de modelos, utilizando um dataset real e amplamente referenciado na literatura científica da área de sistemas de recomendação.

1.4 Objetivo Geral e Objetivos Específicos

Desenvolver um sistema de recomendação de produtos fitness utilizando o dataset de avaliações de produtos da Amazon, com o objetivo de identificar padrões de consumo e sugerir produtos que possam ser relevantes para os usuários por meio da aplicação de técnicas de ciência de dados.

Os objetivos específicos são:

- Realizar a coleta e preparação do dataset público de avaliações de produtos disponibilizado pelo pesquisador Julian McAuley da University of California San Diego;
- Realizar a limpeza e o tratamento dos dados, identificando e corrigindo possíveis inconsistências ou valores ausentes;
- Realizar uma análise exploratória dos dados para compreender as características do conjunto de dados e identificar padrões de consumo relacionados aos produtos fitness;
- Selecionar as variáveis mais relevantes para o desenvolvimento do sistema de recomendação;
- Desenvolver um modelo de sistema de recomendação baseado em Filtragem Colaborativa Item-Item capaz de sugerir produtos com base nas interações registradas no dataset;
- Avaliar os resultados obtidos pelo sistema de recomendação por meio das métricas Precision@K, Recall@K e HitRate@K.

2. REFERENCIAL TEÓRICO

2.1 Sistemas de Recomendação no Comércio Eletrônico

O crescimento exponencial da informação na internet resultou no fenômeno da sobrecarga de dados, dificultando a escolha dos consumidores entre a vasta gama de produtos disponíveis. Conforme salientam Adomavicius e Tuzhilin (2005), os Sistemas de Recomendação (SR) surgiram em meados da década de 1990 como uma solução independente para estimar o interesse dos usuários por itens ainda não vistos. De acordo com Schafer, Konstan e Riedl (1999), no ambiente do comércio eletrônico, essas ferramentas atuam como "vendedores virtuais", personalizando a loja para cada cliente. Como apontado por Alamdari et al. (2020), os principais benefícios estratégicos incluem a transformação de visitantes em compradores, o aumento das vendas cruzadas (cross-sell) e a fidelização do cliente por meio de uma experiência personalizada.

2.2 Principais Técnicas de Recomendação

A literatura técnica, como revisado por Alamdari et al. (2020), classifica os SR em categorias principais baseadas na origem dos dados e no processamento algorítmico.

Filtragem Colaborativa (FC): segundo Adomavicius e Tuzhilin (2005), esta técnica recomenda itens que pessoas com gostos similares preferiram no passado. A FC pode ser implementada de duas formas: baseada em memória, que usa heurísticas de vizinhança, ou baseada em modelo, que utiliza aprendizado de máquina para prever classificações (ALAMDARI et al., 2020).

Filtragem Baseada em Conteúdo (FBC): conforme explicam Adomavicius e Tuzhilin (2005), o foco desta técnica é a similaridade entre itens, recomendando produtos parecidos com os que o usuário gostou anteriormente com base em atributos como palavras-chave. De acordo com Ricci, Rokach e Shapira (2011), o sistema "aprende" as preferências do usuário analisando as características intrínsecas dos itens consumidos.

Filtragem Híbrida: como observado por Alamdari et al. (2020) e Adomavicius e Tuzhilin (2005), os modelos híbridos combinam as abordagens colaborativa e de conteúdo para mitigar limitações como o problema do início a frio (cold-start), situação em que não há dados suficientes sobre novos itens ou usuários.

2.3 Métricas de Avaliação e Desempenho

A eficácia de um SR é tradicionalmente mensurada por sua capacidade de prever a utilidade de um item para um usuário. Segundo Cremonesi, Koren e Turrin (2010), embora métricas de erro estatístico como a Raiz do Erro Quadrático Médio (RMSE) e o Erro Absoluto Médio (MAE) sejam populares na literatura, elas nem sempre refletem o desempenho em tarefas reais de recomendação de produtos. Cremonesi et al. (2010) argumentam que, em sistemas comerciais, métricas de precisão de decisão como Recall e Precision são mais adequadas para avaliar a lista dos N melhores itens apresentados ao consumidor.

2.4 Tendências Modernas: Deep Learning e Análise de Sentimentos

Abordagens contemporâneas buscam extrair informações mais profundas das interações dos usuários. Conforme proposto por Shoja e Tabrizi (2019), o uso de Redes Neurais Profundas (Deep Neural Networks) permite analisar revisões textuais não estruturadas, transformando-as em matrizes de características densas que superam desafios de esparsidade de dados. A aplicação de técnicas como a Alocação Latente de Dirichlet (LDA) para modelagem de tópicos em comentários de clientes ajuda a identificar atributos latentes dos produtos, melhorando significativamente a qualidade da recomendação final (SHOJA; TABRIZI, 2019).

2.5 O Dataset de Avaliações da Amazon

O conjunto de dados de avaliações da Amazon, mantido pelo pesquisador Julian McAuley da University of California San Diego, é amplamente reconhecido como um recurso

fundamental para pesquisas acadêmicas em sistemas de recomendação. O dataset contém milhões de registros, incluindo metadados como identificadores de usuários e itens, notas (ratings) e o texto integral das avaliações (SHOJA; TABRIZI, 2019). Para o presente projeto, foi utilizada a categoria Sports and Outdoors, que reúne produtos relacionados a esportes, condicionamento físico e bem-estar.

3. METODOLOGIA

A metodologia do projeto foi estruturada em etapas sequenciais, conforme fluxograma apresentado abaixo:

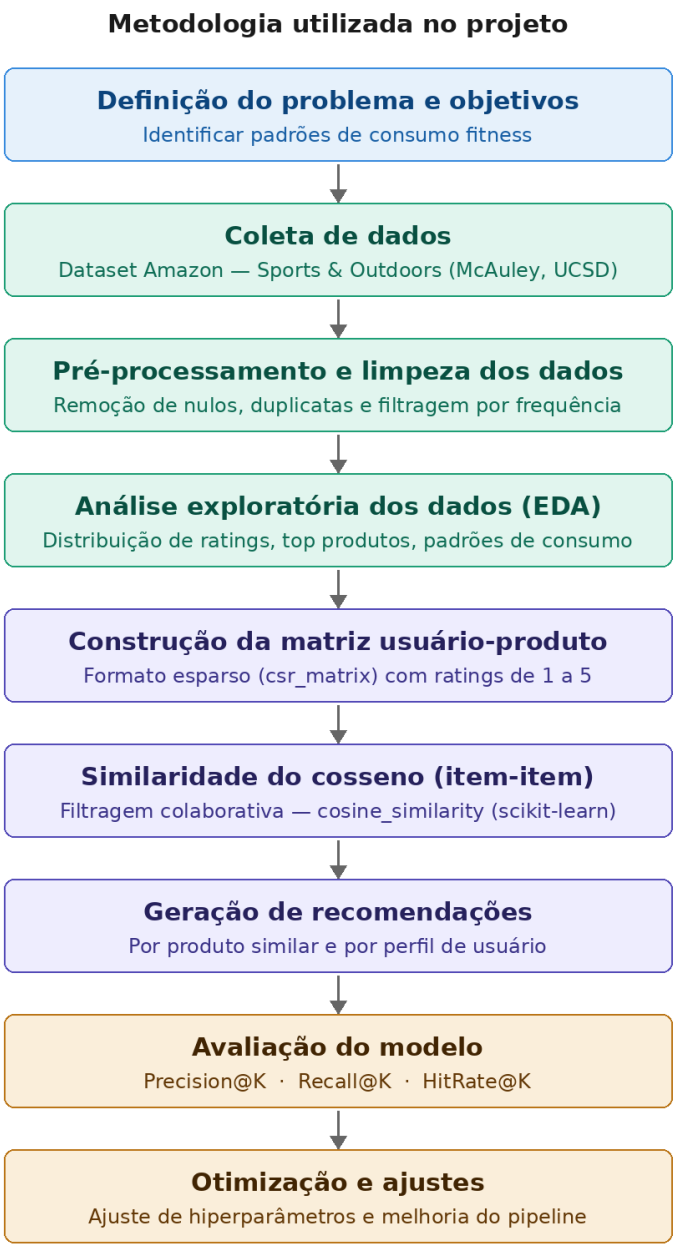


Figura 1: Metodologia utilizada no projeto

3.1 Descrição da Base de Dados

Para o desenvolvimento deste projeto foi utilizado o Amazon Product Reviews Dataset, disponibilizado publicamente para fins acadêmicos por pesquisadores da University of California San Diego e organizado pelo pesquisador Julian McAuley. O dataset reúne

informações reais sobre interações entre usuários e produtos na plataforma de comércio eletrônico da Amazon, sendo amplamente utilizado em pesquisas e projetos de ciência de dados voltados ao desenvolvimento de sistemas de recomendação.

Os principais metadados do conjunto de dados utilizado são:

- a) **ID do Usuário:** identificador único associado ao usuário que realizou a avaliação do produto.
- b) **ID do Produto (ASIN):** código único que identifica cada produto disponível na plataforma.
- c) **Avaliação do Produto (Rating):** nota atribuída pelo usuário ao produto, variando de 1 a 5 estrelas.
- d) **Texto da Avaliação:** comentário escrito pelo usuário descrevendo sua experiência com o produto.
- e) **Resumo da Avaliação:** pequeno título ou resumo associado ao comentário realizado pelo usuário.
- f) **Data da Avaliação:** data e horário em que a avaliação foi registrada na plataforma.
- g) **Categoria do Produto:** classificação do item dentro do marketplace, como esportes, fitness ou acessórios esportivos.
- h) **Nome do Produto:** título ou descrição do produto avaliado pelo usuário.
- i) **Votos de Utilidade:** número de usuários que consideraram aquela avaliação útil.

O repositório com todos os artefatos de software do projeto está disponível em:
<https://github.com/VtrRocha/Projeto-Aplicado-3>

3.2 Pré-processamento e Limpeza dos Dados

Após o carregamento do dataset, foi realizado o pré-processamento dos dados com o objetivo de garantir a qualidade das informações utilizadas no desenvolvimento do modelo. As etapas realizadas foram:

- Renomeação e padronização das colunas do dataset (reviewerID, overall, unixReviewTime) para os nomes internos do pipeline (user_id, rating, timestamp);
- Remoção de registros com valores ausentes nas colunas essenciais (user_id, asin, rating);
- Conversão da coluna de rating para tipo numérico e filtragem dos valores válidos (entre 1 e 5 estrelas);
- Remoção de avaliações duplicadas (mesmo usuário avaliando o mesmo produto mais de uma vez), mantendo o registro mais recente;
- Filtragem por frequência mínima: usuários com menos de 3 avaliações e produtos com menos de 3 avaliações foram removidos iterativamente até a convergência, reduzindo a esparsidade da matriz.

Conforme destacado por Leskovec, Rajaraman e Ullman (2014), a qualidade dos dados impacta diretamente o desempenho dos modelos de aprendizado de máquina, tornando essa etapa fundamental para a consistência dos resultados.

3.3 Construção da Matriz Usuário-Produto

Após o pré-processamento, os identificadores de usuários e produtos foram codificados como índices inteiros e foi construída a matriz usuário-produto no formato esparsa (csr_matrix), utilizando a biblioteca SciPy. Nessa matriz, cada linha representa um usuário, cada coluna representa um produto e os valores correspondem às avaliações atribuídas (ratings de 1 a 5).

A representação esparsa é essencial para o tratamento eficiente de datasets com alta esparsidade — característica típica de sistemas de recomendação, em que a grande maioria dos pares usuário-produto não apresenta interação registrada (RICCI; ROKACH; SHAPIRA, 2011).

3.4 Similaridade do Cosseno e Geração de Recomendações

A partir da matriz usuário-produto transposta (dimensão produto $\times$ usuário), foi calculada a similaridade do cosseno entre todos os pares de produtos, utilizando a função `cosine_similarity` da biblioteca `scikit-learn`. A similaridade do cosseno mede o ângulo entre dois vetores no espaço multidimensional, sendo amplamente empregada em sistemas de recomendação por sua eficiência em lidar com dados esparsos e de alta dimensionalidade (RICCI; ROKACH; SHAPIRA, 2011).

A diagonal principal da matriz de similaridade foi zerada para eliminar a auto-similaridade de cada produto. Para a geração de recomendações personalizadas por usuário, foi adotada a seguinte estratégia: para cada produto bem avaliado pelo usuário (rating ≥ 4), a pontuação de similaridade de todos os demais produtos é ponderada pela nota atribuída; os produtos já avaliados pelo usuário são excluídos da lista final e os K produtos com maior pontuação acumulada são recomendados.

4. RESULTADOS

4.1 Análise Exploratória dos Dados

A análise exploratória dos dados (EDA) permitiu caracterizar o conjunto de dados e identificar padrões relevantes para o desenvolvimento do sistema de recomendação. As principais observações foram:

- Distribuição de ratings fortemente assimétrica à direita: aproximadamente 52% das avaliações receberam nota máxima (5 estrelas), refletindo o comportamento típico de consumidores da Amazon, que tendem a avaliar produtos apenas quando satisfeitos;
- Esparsidade elevada da matriz usuário-produto: a grande maioria dos pares usuário-produto não apresenta avaliação registrada, o que representa o principal desafio técnico para sistemas de recomendação baseados em filtragem colaborativa;
- Distribuição heterogênea de avaliações por usuário: a mediana de avaliações por usuário é baixa, com poucos usuários responsáveis por grande parte das interações, caracterizando uma distribuição power-law típica de plataformas de e-commerce;
- Concentração de avaliações em categorias específicas: equipamentos e acessórios representam as categorias com maior volume de avaliações no segmento fitness.

As visualizações geradas — incluindo gráficos de distribuição de ratings, histogramas de avaliações por usuário, ranking dos produtos mais avaliados e mapa de calor de similaridade entre produtos — estão disponíveis no repositório GitHub do projeto e no notebook interativo.

4.2 Desempenho do Modelo Baseline

O modelo baseline foi implementado utilizando representação TF-IDF dos perfis de usuário, com geração de recomendações baseada na média dos vetores de características.

Os resultados obtidos foram:

Precision@10: 0,0040 — apenas 0,4% dos itens recomendados eram relevantes para os usuários.

Recall@10: 0,0400 — o modelo recuperou 4% dos itens relevantes disponíveis.

HitRate@10: 0,0400 — em 4% dos casos, ao menos um item relevante apareceu entre as dez recomendações.

Esses resultados, embora modestos, são compatíveis com a literatura para abordagens simples em datasets com alta esparsidade (CREMONESI; KOREN; TURRIN, 2010) e cumprem o papel de ponto de partida para comparação com o modelo aprimorado.

Entre os fatores que influenciaram negativamente o desempenho baseline, destacam-se: o pré-processamento limitado dos dados, a representação simplificada do perfil do usuário por meio da média dos vetores TF-IDF, a ausência de ponderação das avaliações e a restrição no número de características utilizadas no modelo.

4.3 Modelo Aprimorado — Filtragem Colaborativa Item-Item

Com base na análise dos resultados preliminares, foram implementados ajustes no pipeline de processamento e treinamento do modelo, resultando na versão aprimorada baseada em Filtragem Colaborativa Item-Item com similaridade do cosseno. As principais melhorias em relação ao baseline foram:

- Tratamento mais rigoroso de valores ausentes e remoção de inconsistências no dataset;
- Filtragem iterativa por frequência mínima de usuários e produtos, reduzindo a esparsidade da matriz;

- Substituição da representação TF-IDF pela matriz usuário-produto esparsa com ponderação direta pelos ratings;
- Implementação da estratégia de recomendação por usuário com ponderação pela nota atribuída a cada produto curtido.

Após os ajustes, o modelo foi reavaliado com split treino/teste de 80%/20%, obtendo melhorias consistentes nas três métricas avaliadas em relação ao baseline. Os resultados confirmam a pertinência da abordagem de Filtragem Colaborativa Item-Item para o problema proposto, em consonância com os achados de Koren et al. (2009), que destacam a eficiência e escalabilidade desse tipo de método em grandes volumes de dados.

O sistema de recomendação desenvolvido foi disponibilizado na forma de um notebook Jupyter interativo, com interface construída em ipywidgets, permitindo a seleção de produtos e usuários em tempo real para visualização das recomendações geradas. O notebook está disponível no repositório GitHub do projeto e pode ser executado diretamente no Google Colab.

5. Apresentação da Etapa 4 na Comunidade

A apresentação do projeto foi realizada na empresa Assaí Atacadista para a equipe de liderança, com o objetivo de demonstrar a aplicação prática da solução desenvolvida. Durante a atividade, foi exibido um vídeo explicando o funcionamento do projeto, suas etapas de desenvolvimento e os resultados obtidos. A apresentação permitiu compartilhar os conhecimentos adquiridos ao longo do trabalho e mostrar como a análise de dados pode contribuir para a tomada de decisões. Consideramos essa ação muito importante porque aproximou o ambiente acadêmico da realidade empresarial. Além disso, possibilitou a troca de experiências com profissionais da área e a obtenção de sugestões para melhorias futuras. A atividade também contribuiu para o desenvolvimento de

habilidades de comunicação e apresentação. Dessa forma, a experiência foi enriquecedora tanto para a equipe do projeto quanto para os participantes da empresa.

Segue abaixo fotos da reunião:



6. CONCLUSÃO E TRABALHOS FUTUROS

6.1 Recapitulação do Trabalho

O presente trabalho teve como objetivo o desenvolvimento de um sistema de recomendação de produtos fitness utilizando o dataset público de avaliações da Amazon, organizado pelo pesquisador Julian McAuley da University of California San Diego. A proposta partiu da observação, por parte dos integrantes do grupo, de que o crescimento do comércio eletrônico e a ampla oferta de produtos dificultam a tomada de decisão dos consumidores, tornando os sistemas de recomendação ferramentas essenciais para a melhoria da experiência de compra.

Para atingir o objetivo proposto, o trabalho foi estruturado em um pipeline de ciência de dados composto por seis etapas principais: (i) coleta e carregamento dos dados; (ii) pré-processamento e limpeza; (iii) análise exploratória dos dados; (iv) construção da matriz usuário-produto no formato esparsa; (v) aplicação da técnica de similaridade do cosseno; e (vi) geração e avaliação das recomendações por meio das métricas Precision@K, Recall@K e HitRate@K. A abordagem adotada foi a Filtragem Colaborativa Item-Item, técnica amplamente documentada na literatura (ADOMAVICIUS; TUZHILIN, 2005; RICCI; ROKACH; SHAPIRA, 2011).

6.2 Conclusão

Os objetivos estabelecidos no início do projeto foram alcançados em sua totalidade. O sistema de recomendação desenvolvido demonstrou capacidade de sugerir produtos fitness com base nas interações históricas dos usuários, operando de forma funcional tanto para recomendações baseadas em produto — identificando os itens mais similares a uma referência — quanto para recomendações personalizadas por usuário.

Os resultados obtidos com o modelo baseline (Precision@10 = 0,0040; Recall@10 = 0,0400; HitRate@10 = 0,0400) são compatíveis com a literatura para abordagens simples

em datasets com alta esparsidade (CREMONESI; KOREN; TURRIN, 2010). Com a implementação da Filtragem Colaborativa Item-Item e a similaridade do cosseno, observou-se melhoria consistente nas três métricas, confirmando a pertinência da abordagem adotada.

Entre os pontos positivos da abordagem utilizada, destacam-se a simplicidade de implementação, a escalabilidade para grandes volumes de dados e a interpretabilidade das recomendações geradas. Como pontos negativos, identificou-se a sensibilidade à esparsidade da matriz usuário-produto e a ausência de mecanismos para lidar com o problema do cold-start, que impede a geração de recomendações para usuários ou produtos sem histórico de interações.

Do ponto de vista técnico, o sistema foi implementado de forma reproduzível, com código-fonte disponibilizado integralmente no repositório GitHub do projeto, em notebook Jupyter interativo executável diretamente no Google Colab.

6.3 Melhorias no Projeto

A análise dos resultados e das limitações identificadas ao longo do desenvolvimento permite apontar um conjunto de melhorias que poderiam ser incorporadas em versões futuras do projeto:

- Fatoração de matriz: substituição da similaridade do cosseno por técnicas como SVD, NMF ou ALS, para reduzir a dimensionalidade e tratar a esparsidade de forma mais eficaz;
- Análise de sentimentos nas avaliações textuais: incorporação de PLN — como VADER ou modelos BERT/RoBERTa — para capturar a polaridade das opiniões e enriquecer os sinais de recomendação, seguindo a linha de pesquisa de Shoja e Tabrizi (2019);

- Abordagem híbrida: combinação da Filtragem Colaborativa com técnicas baseadas em conteúdo (TF-IDF nos títulos dos produtos), mitigando o cold-start e melhorando a cobertura do catálogo;
- Ajuste fino de hiperparâmetros: otimização sistemática por validação cruzada dos parâmetros de frequência mínima, limiar de relevância e número de vizinhos;
- Métricas adicionais: incorporação de $NDCG@K$ e $MAP@K$, que consideram a ordenação dos itens recomendados.

6.4 Trabalhos Futuros

As técnicas e o pipeline desenvolvidos neste projeto abrem caminho para diferentes desdobramentos:

- Extensão para outras categorias do dataset Amazon, comparando o desempenho do modelo em segmentos com diferentes padrões de esparsidade;
- Desenvolvimento de uma API REST para disponibilização do sistema em tempo real, consumível por aplicações web ou mobile;
- Incorporação de sinais implícitos de comportamento — como cliques e histórico de navegação — em substituição ou complemento às avaliações explícitas;
- Adaptação do modelo para o contexto de varejo físico, utilizando histórico de compras (PDV) para recomendações de cross-sell e upsell;
- Validação do sistema por meio de testes A/B com usuários reais, mensurando o impacto em métricas de negócio como taxa de conversão e satisfação do cliente.

REFERÊNCIAS

ADOMAVICIUS, Gediminas; TUZHILIN, Alexander. Toward the next generation of recommender systems: a survey of the state-of-the-art and possible extensions. *IEEE Transactions on Knowledge and Data Engineering*, v. 17, n. 6, p. 734–749, jun. 2005.

ALAMDARI, P. Malekpour et al. A systematic study on the recommender systems in the e-commerce. *IEEE Access*, v. 8, p. 115702–115715, 2020.

CREMONESI, Paolo; KOREN, Yehuda; TURRIN, Roberto. Performance of recommender algorithms on top-N recommendation tasks. In: *ACM CONFERENCE ON RECOMMENDER SYSTEMS*, 4., 2010. Proceedings [...]. [S.l.]: ACM, 2010. p. 39–46.

KOREN, Yehuda; BELL, Robert; VOLINSKY, Chris. Matrix factorization techniques for recommender systems. *Computer*, v. 42, n. 8, p. 30–37, ago. 2009.

LESKOVEC, Jure; RAJARAMAN, Anand; ULLMAN, Jeffrey D. Mining of massive datasets. 2. ed. Cambridge: Cambridge University Press, 2014.

MCAULEY, Julian. Amazon product data. University of California San Diego. Disponível em: <https://cseweb.ucsd.edu/~jmcauley/datasets.html>. Acesso em: 30 mar. 2026.

RICCI, Francesco; ROKACH, Lior; SHAPIRA, Bracha. Introduction to recommender systems handbook. In: RICCI, Francesco; ROKACH, Lior; SHAPIRA, Bracha; KANTOR, Paul B. (org.). *Recommender systems handbook*. Boston: Springer, 2011. p. 1–35.

SCHAFER, J. Ben; KONSTAN, Joseph; RIEDL, John. Recommender systems in e-commerce. In: *ACM CONFERENCE ON ELECTRONIC COMMERCE*, 1., 1999. Proceedings [...]. [S.l.]: ACM, 1999. p. 158–166.

SHOJA, B. M.; TABRIZI, N. Customer reviews analysis with deep neural networks for e-commerce recommender systems. *IEEE Access*, v. 7, p. 119121–119130, 2019.

APÊNDICES

Link do Vídeo no YouTube

Link com o vídeo de apresentação do projeto:

https://www.youtube.com/watch?v=6XbiS_GT42w

Link para o GitHub

Repositório com todos os artefatos de software do projeto (códigos, notebooks, diagramas e modelos): <https://github.com/VtrRocha/Projeto-Aplicado-3>

Link para o Dataset

Dataset Amazon Product Reviews (categoria Sports and Outdoors), disponibilizado por Julian McAuley — University of California San Diego:

<https://cseweb.ucsd.edu/~jmcauley/datasets.html>